

1

1. 推导线性回归模型的贝叶斯估计。给定训练数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$, 其中 $\mathbf{x}_i \in \mathbb{R}^n, y_i \in \mathbb{R}$. 考虑线性回归模型: $y = \mathbf{w}^T \mathbf{x} + e$, 其中, 假设 e 服从零均值、方差为 σ^2 的高斯分布。若已知 \mathbf{w} 服从零均值、协方差矩阵为 Λ 的高斯分布, 其中 Λ 是对角矩阵, 对角元素为 $\{\lambda_i\}_{i=1}^n$. 试基于最大后验概率准则估计模型参数, 给出详细推导步骤。

2. 在题目 2 中, 若 \mathbf{w} 采用共轭先验, 即假设 \mathbf{w} 服从零均值、协方差矩阵为 Λ 的高斯分布, 请基于完全贝叶斯准则推导回归模型, 给出预测性分布密度函数和每个参数的后验步骤。(提示: 即后验函数的分布密度; 后验分布密度; 预测性分布密度函数; “配方法”)

1

3. 对于包含 k 个类别的分类问题, 分析比较一下线性判别函数模型、概率生成模型和概率判别模型。提示: 可以从以下几个方面比较: 模型的输入和输出、模型形式是否是线性、目标函数、以及学习算法(求解参数的方法)等。

模型名称	模型输入/输出	模型参数/目标函数	模型求解/学习算法
线性判别函数模型	输入: 特征向量 \mathbf{x} ; 输出: 类别 k	参数: 判别函数 $g_k(\mathbf{x})$	求解: 最大化判别函数的最小值
概率生成模型	输入: 特征向量 \mathbf{x} ; 输出: 类别 k 的概率 $p(k \mathbf{x})$	参数: 联合概率分布 $p(\mathbf{x}, k)$	求解: 最大化对数似然函数
概率判别模型	输入: 特征向量 \mathbf{x} ; 输出: 类别 k 的概率 $p(k \mathbf{x})$	参数: 判别函数 $g_k(\mathbf{x})$	求解: 最大化判别函数的最小值

Ex: Data: $\{(x_i, y_i)\}_{i=1}^N$.

$x_i \in \mathbb{R}^T, y_i \in \mathbb{R}$.

$$X = \begin{pmatrix} x_1 & x_2 & \dots & x_N \end{pmatrix}^T = \begin{pmatrix} x_{11} & \dots & x_{1p} \\ x_{21} & \dots & x_{2p} \\ \vdots & & \vdots \\ x_{N1} & \dots & x_{Np} \end{pmatrix}_{N \times p}$$

$$Y = (y_1, y_2, \dots, y_N)^T_{N \times 1}$$

$$\text{Model: } \begin{cases} f(w) = w^T x \\ y = f(w) + e, \quad e \sim \mathcal{N}(0, \sigma^2) \end{cases}$$

Bayesian Method: ① Inference: posterior $\pi(w)$.

② Prediction: $x^* \rightarrow y^*$ $\nearrow = P(y|x)P(Y|X)$

$$\textcircled{1} \text{ Inference. } P(w | \text{Data}) = P(w | X, Y) = \frac{P(w, Y | X)}{P(Y | X)} = \frac{\overset{\text{Likelihood}}{P(Y | w, X)} \overset{\text{Prior}}{P(w)}}{\int P(Y | w, X) P(w) dw} = \frac{P(w, Y | X)}{P(w, X)}$$

$$P(Y | w, X) = \prod_{i=1}^N P(y_i | w; x_i) = \prod_{i=1}^N \mathcal{N}(y_i | w^T x_i, \sigma^2).$$

$$P(w) = \mathcal{N}(0, \Sigma_p^{-1}) \quad \text{已知点} \rightarrow \text{先验: Gaussian 分布逆高斯先验}$$

$$P(w | \text{Data}) \propto P(Y | w, X) P(w) \propto \prod_{i=1}^N \mathcal{N}(y_i | w^T x_i, \sigma^2) \cdot \mathcal{N}(0, \Sigma_p^{-1}) \xrightarrow{\text{高维矩阵求逆}} \mathcal{N}(\mu_w, \Sigma_w)$$

Gaussian Gaussian Gaussian

后验也是一高斯分布。

$$\begin{aligned} P(Y | w, X) &= \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2} (y_i - w^T x_i)^2\right\} \\ &= \frac{1}{(2\pi)^{\frac{N}{2}} \sigma^N} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - w^T x_i)^2\right\} \\ &= \frac{1}{(2\pi)^{\frac{N}{2}} \sigma^N} \exp\left\{-\frac{1}{2} (Y - Xw)^T \sigma^{-2} I (Y - Xw)\right\} \end{aligned}$$

这一步具体步骤:

$$\begin{aligned} \sum_{i=1}^N (y_i - w^T x_i)^2 &= (y_1 - w^T x_1, y_2 - w^T x_2, \dots, y_N - w^T x_N) \begin{pmatrix} y_1 - w^T x_1 \\ y_2 - w^T x_2 \\ \vdots \\ y_N - w^T x_N \end{pmatrix} \\ &= (Y - Xw)^T (Y - Xw) \end{aligned}$$

$$P(w | \text{Data}) \propto \mathcal{N}(Xw, \sigma^{-2} I) \mathcal{N}(0, \Sigma_p^{-1})$$

$$\propto \exp\left\{-\frac{1}{2} (Y - Xw)^T \sigma^{-2} I (Y - Xw)\right\} \cdot \exp\left\{-\frac{1}{2} w^T \Sigma_p^{-1} w\right\}$$

$$= \exp\left\{-\frac{1}{2\sigma^2} (Y^T - w^T X^T) (Y - Xw) - \frac{1}{2} w^T \Sigma_p^{-1} w\right\}$$

$$= \exp\left\{-\frac{1}{2\sigma^2} \left(Y^T Y - 2Y^T Xw - \underbrace{w^T X^T Y + w^T X^T Xw}_{\text{高维矩阵求逆求高维}} - \frac{1}{2} w^T \Sigma_p^{-1} w \right)\right\}$$

$$\text{上式中间求和项: } -\frac{1}{2\sigma^2} w^T X^T Xw - \frac{1}{2\sigma^2} w^T \Sigma_p^{-1} w = \frac{1}{2} w^T (\sigma^{-2} X^T X + \Sigma_p^{-1}) w$$

$$\text{上式中间求和项: } -\frac{1}{2\sigma^2} (-2) Y^T Xw = \underbrace{\sigma^{-2} Y^T Xw}_{\mu_w^T \Sigma_w^{-1} = \mu_w^T A}$$

$$\mu_w^T \Sigma_w^{-1} = \mu_w^T A$$

$$\text{则 } \mu_w = (\sigma^{-2} Y^T X)^T A^{-1} = \sigma^{-2} A^{-1} X^T Y$$

综上, $P(w | \text{Data}) = \mathcal{N}(\mu_w, \Sigma_w)$, 其中, $\mu_w = \sigma^{-2} A^{-1} X^T Y$.

$$\Sigma_w = A^{-1} \quad (A = \sigma^{-2} X^T X + \Sigma_p^{-1})$$

综上, $P(w | \text{Data}) = \mathcal{N}(\mu_w, \Sigma_w)$, 其中, $\mu_w = \sigma^{-2} A^{-1} X^T Y$.

$$\Sigma_w = A^{-1} \quad (A = \sigma^{-2} X^T X + \Sigma_p^{-1})$$

② Prediction

$$\text{Model: } \begin{cases} f(x) = w^T x = x^T w \\ y = f(w) + e, \quad e \sim \mathcal{N}(0, \sigma^2) \end{cases}$$

给定特征 x^* , 求 $f(x^*) = x^{*T} w$

$$\because w \sim \mathcal{N}(\mu_w, \Sigma_w) \quad \therefore f(x^*) \sim \mathcal{N}(x^{*T} \mu_w, x^{*T} \Sigma_w x^*)$$

$$\therefore y^* = f(x^*) + e. \sim \mathcal{N}(x^{*T} \mu_w, x^{*T} \Sigma_w x^* + \sigma^2)$$